

EP4

Flora Matsubara Hollander nUSP 11811221
Rodrigo Meireles de Oliveira nUSP 7580967

Junho 2021

Objetivo


A partir do modelo estatístico apresentado em aula, neste exercício-programa implementaremos a função $U(v)$ que aproxima bem a função-verdade pedida $W(v)$ utilizando as definições e aproximações do enunciado. É necessário que o erro desta seja menor que 0.05%, portanto foi necessário o cálculo de n (nº de pontos θ_n) suficientemente grande.

Método

Primeiro, para a função $f(\theta|x,y)$ definimos $f(alpha, theta)$ utilizando a função densidade Dirichlet. Em *im_f* armazenamos o resultado de $f(alpha, theta)$ calculado para cada um dos n thetas sorteados por Dirichlet. A partir desses valores, geramos os bins com a quantidade de valores por bin desejada com a função *qcut()* do pacote *pandas*.

(7.136e-05, 7.1364e-05]	34
(2.9684e-05, 2.9691e-05]	34
(2.9737e-05, 2.9745e-05]	34
(2.9729e-05, 2.9737e-05]	34
(2.9721e-05, 2.9729e-05]	34
...	...
(5.1643e-05, 5.165e-05]	34
(5.1636e-05, 5.1643e-05]	34
(5.163e-05, 5.1636e-05]	34
(5.1623e-05, 5.163e-05]	34
(-9.9985344e-06, 5.259e-08]	34

Bins de $f(\theta)$ e número de valores por bin



Histograma dos bins de $f(\theta)$

Para encontrar uma aproximação de $W(v)$, temos que

$$W(t_j) - W(t_{j-1}) \approx \frac{1}{k} \Rightarrow W(t_j) \approx \frac{j}{k}$$

Ou seja, como a integral em intervalo pode ser aproximada por $1/k$, o valor até um ponto pode ser aproximada pela soma da integral de cada intervalo anterior a ele. A função $U(v)$ realiza uma busca binária nos valores dos bins para localizar o índice do intervalo aproximado de v e divide seu valor por k .

A fim de garantir que o erro cometido pela função seja menor que 0.05%, utilizamos $k = 10000$, já que queremos $\frac{1}{k} \leq 0.05\%$. Além disso, utilizamos a inequação de Dvoretzky-Kiefer-Wolfowitz¹ para estimar n suficientemente grande. Para um intervalo de confiança com significância 95%, sendo $\epsilon = 0.05\%$ o erro desejado, temos:

$$P(\sup_{t \in \mathbb{R}^d} |F_n(t) - F(t)| > \epsilon) \leq (n+1)de^{-2n\epsilon^2} < 0.05$$

Em que $d = 3$ é a dimensão dos vetores. Segunda a referência, para n suficientemente grande podemos substituir $(n+1)$ por 2, obtemos

$$6e^{-2n0.0005^2} < 0.05 \Rightarrow n \geq -\frac{\ln(\frac{0.05}{6})}{5 \times 10^{-7}}$$

Código

```
1 '''Flora Matsubara Hollander nUSP 11811221 & Rodrigo Meireles de Oliveira nUSP
   7580967
2   Declaramos este trabalho como público.'''
3
4 import numpy as np
5 import pandas as pd
6 import math
7
8 rng = np.random.default_rng(2021) #seed para reproducibilidade
9 x = [3, 2, 1] #x e y do enunciado <==== PARÂMETROS PARA OS MONITORES
10 y = [1, 2, 3]
11 alpha = [i+j for i, j in zip(x,y)]
12 k = 10000
13 beta_cte = np.prod([math.gamma(a) for a in alpha])/math.gamma(np.sum(alpha))
14
15 def f(alpha, theta): #função densidade Dirichlet
16     return np.prod([t**(a - 1) for a, t in zip(alpha, theta)])/beta_cte
17
18 n = int(np.ceil(np.log(0.05/6)/-5e-7)) #aplicando desigualdade DKW para encontrar
   n tal que o erro de integração é menor que 0.0005 em 95% das vezes
19 print(f'Precisamos de {n} pontos da Dirichlet.')
20
21 thetas = rng.dirichlet(alpha, size = n)
22 im_f = [f(alpha, theta) for theta in thetas]
23 max_f = np.max(im_f)
24 bins = pd.qcut(im_f, q = k, retbins = True)[1] #função do pandas que cria os bins
   com quantidade de valores iguais por quantil
25 bins[0] = 0
26
27 def U(v):
28     '''Aproximação de W(v), recebe v e retorna o valor da integral das caudas i.e. a
   integral de f(t) para todo t tal que f(t) <= f(v)'''
29     if v <= min(im_f):
30         return 0
31     elif v >= max(im_f):
32         return 1
33     else:
34         return (np.searchsorted(bins, v))/k #busca binária nos valores dos intervalos,
   ele descobre o valor de v pra saber em qual intervalo o v fica
   #pq a integral é até <= v
35
```

O código acima retorna a função $U(v)$ como desejado. Os testes $U(1)$ e $U(0.5)$ retornam **0.0589** e **0.0244** respectivamente, condizente com a precisão pedida.

¹Baseado em https://en.wikipedia.org/wiki/Dvoretzky%E2%80%93Kiefer%E2%80%93Wolfowitz_inequality